



Escuela Politécnica Nacional

Facultad de Ingeniería de Sistemas

Construcción y Evolución del Software – GR2SW

**Taller Práctico: Reingeniería de Procesos e
Integración de Nuevas Tecnologías**

Grupo 03

Integrantes:

- Elían Caizapanta
- Brandon Pallo
- Fernanda Rueda

Fecha de Entrega: 21 de abril de 2026

Docente: MSc. Adrián Eguez

2026-A



ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA DE SISTEMAS
CONSTRUCCIÓN Y EVOLUCIÓN DEL
SOFTWARE

Tabla de contenido

1.	Introducción.....	1
2.	Proceso 1: Sistema de Moderación de Chat en Vivo.....	1
2.1.	Diagnóstico del Proceso Actual (As-Is).....	1
2.2.	Diseño de la Reingeniería (To-Be)	2
2.3.	Impacto y Beneficios	4
3.	Proceso 2: Sistema de Descubrimiento y Recomendación de Canales	4
3.1.	Diagnóstico del Proceso Actual (As-Is).....	4
3.2.	Diseño de la Reingeniería (To-Be)	5
3.3.	Impacto y Beneficios	8
4.	Diagrama de Arquitectura de Alto Nivel.....	8
5.	Resumen Comparativo de la Reingeniería	9
6.	Conclusión.....	9



Introducción

Kick.com es una plataforma de streaming en vivo fundada en 2022 y lanzada oficialmente en 2023, que se ha posicionado como una alternativa directa a Twitch. Su propuesta de valor central es un modelo de monetización más favorable para los creadores de contenido: ofrece una división de ingresos del 95/5 (95% para el streamer), en contraste con el 50/50 de Twitch. La plataforma ha crecido rápidamente, atrayendo a streamers y audiencias que buscan condiciones más justas y políticas de contenido más flexibles.

Para este taller, el equipo ha seleccionado dos procesos críticos dentro de Kick.com que presentan oportunidades claras de reingeniería utilizando tecnologías modernas.

Proceso 1: Sistema de Moderación de Chat en Vivo

Diagnóstico del Proceso Actual (As-Is)

¿Cómo funciona hoy?

El sistema de moderación de chat en Kick.com funciona de manera predominantemente manual y reactiva. El streamer puede designar moderadores humanos voluntarios (llamados "mods") que monitorean el flujo de mensajes en tiempo real. La plataforma ofrece herramientas básicas como:

- Baneos manuales por palabras clave configuradas previamente.
- Timeouts (silenciamiento temporal) aplicados por los mods.
- Filtros de spam rudimentarios que bloquean mensajes repetidos.
- Reportes de usuarios enviados por la comunidad para revisión manual posterior.

Cuellos de botella y limitaciones actuales:

1. *Escalabilidad nula ante picos de audiencia:* En transmisiones con miles de usuarios simultáneos (como eventos de juegos populares o partidas de apuestas), el chat se mueve a velocidades que ningún moderador humano puede seguir. Los mensajes tóxicos, el spam y el acoso quedan visibles por minutos antes de ser eliminados.
2. *Dependencia total del factor humano:* Si no hay mods activos o están dormidos (en streams nocturnos o de otras zonas horarias), el chat queda completamente desprotegido. La plataforma no tiene una capa de protección automática inteligente.
3. *Falta de contexto en los filtros:* Los filtros de palabras clave son extremadamente primitivos — bloquean términos de forma literal sin entender contexto. Por ejemplo, bloquean la palabra sin distinguir si se usa de forma ofensiva o en una conversación normal, generando tanto falsos positivos como falsos negativos.



4. *Sin aprendizaje adaptativo*: El sistema no aprende del comportamiento histórico de los usuarios. Un usuario que ha sido baneado 10 veces puede crear una nueva cuenta y actuar inmediatamente sin ninguna restricción adicional.
5. *Carga excesiva sobre los streamers*: Muchos streamers pequeños no tienen mods y deben dividir su atención entre jugar/crear contenido y monitorear el chat, degradando la calidad del stream.

Diseño de la Reingeniería (To-Be)

Transformación Técnica:

La propuesta es implementar un Sistema de Moderación Inteligente Multi-Agente basado en LLM con la siguiente arquitectura:

Capa 1 — Agente de Análisis Semántico en Tiempo Real:

Se despliega un modelo de lenguaje liviano (fine-tuned sobre datos de comunidades de gaming y streaming) que analiza cada mensaje del chat no solo por palabras clave, sino por intención y contexto conversacional. Este agente asigna un "score de toxicidad" a cada mensaje en menos de 50 milisegundos.

Capa 2 — Agente de Perfilado de Usuario:

Un sistema que construye y actualiza continuamente un perfil de comportamiento de cada usuario basado en su historial: frecuencia de mensajes, patrones de spam, reportes recibidos, baneos previos (incluso en cuentas anteriores detectadas por fingerprinting de dispositivo). Este agente retroalimenta al Agente de Análisis Semántico con contexto adicional.

Capa 3 — Agente Orquestador de Acciones:

Recibe las señales de los dos agentes anteriores y ejecuta acciones graduales automáticamente:

- Score bajo → mensaje permitido.
- Score medio → mensaje marcado y puesto en cola para revisión humana.
- Score alto → timeout automático de 10 minutos con notificación al mod.
- Score crítico + historial negativo → baneo temporal automático y escalamiento al equipo de Kick.

Capa 4 — Panel de Supervisión para Mods:


Una interfaz rediseñada donde los moderadores humanos ya no vigilan el chat completo, sino que solo revisan los casos marcados por la IA, con contexto completo del usuario y del mensaje. La IA hace el trabajo pesado; los humanos toman decisiones en los casos ambiguos.



Infraestructura Cloud:

- Procesamiento de mensajes con Apache Kafka para manejo de streams de alta velocidad.
- Modelos LLM desplegados en contenedores con auto-scaling en AWS/GCP según la audiencia activa del canal.
- Base de datos de perfiles de usuario en Redis (baja latencia) con respaldo en PostgreSQL.

Flujo Propuesto (To-Be):





Impacto y Beneficios

Beneficio	Descripción
Escalabilidad total	El sistema procesa miles de mensajes por segundo sin degradarse, independientemente del tamaño de la audiencia
Reducción de tiempo de respuesta	De minutos (moderación manual) a milisegundos (moderación automática)
Eliminación de la dependencia humana constante	Los streamers pequeños sin mods tienen protección activa las 24 horas
Precisión contextual	El LLM entiende jerga de gaming, sarcasmo y contexto, reduciendo falsos positivos en ~70% comparado con filtros de palabras clave
Aprendizaje continuo	El sistema mejora con cada decisión de moderación, adaptándose a nuevas formas de acoso o spam
Mejor experiencia de comunidad	Los usuarios legítimos sufren menos interrupciones; el chat se vuelve un espacio más seguro y atractivo

Proceso 2: Sistema de Descubrimiento y Recomendación de Canales

Diagnóstico del Proceso Actual (As-Is)

¿Cómo funciona hoy?

El sistema de descubrimiento de contenido en Kick.com es extremadamente básico. Los usuarios encuentran canales principalmente a través de:

- Una página de inicio con listado de canales ordenados por número de espectadores (los más vistos primero).
- Una barra de búsqueda donde el usuario debe saber exactamente qué juego o streamer buscar.
- Categorías generales (FPS, RPG, Gambling, IRL, etc.) que muestran todos los streams activos de esa categoría, también ordenados por viewers.
- Recomendaciones de canales dentro del stream que se está viendo (generalmente canales del mismo streamer que sigue a otros).

Cuellos de botella y limitaciones actuales:

1. *El "rich get richer" problem:* El algoritmo actual favorece masivamente a los streamers ya populares. Un canal con 10,000 viewers siempre aparece primero, haciendo casi imposible que canales pequeños sean descubiertos orgánicamente. Esto desincentiva a nuevos creadores.



2. *Cero personalización*: La plataforma muestra exactamente el mismo listado de canales para todos los usuarios, sin importar sus preferencias, historial de visualización o el horario en que se conectan. Un usuario que solo ve contenido de RPGs en español ve la misma portada que alguien que solo ve FPS en inglés.
3. *Sin comprensión del contexto del usuario*: La plataforma no sabe si el usuario tiene 10 minutos para ver contenido casual o si está disponible para ver un stream de 4 horas. No adapta las sugerencias al estado contextual del usuario.
4. *Baja retención*: Sin recomendaciones relevantes cuando termina un stream, los usuarios simplemente cierran la plataforma en lugar de descubrir nuevo contenido. Esto representa una pérdida directa de tiempo de sesión y, consecuentemente, de ingresos por publicidad.
5. *Incapacidad de conectar comunidades*: No existe un mecanismo que conecte a usuarios con comunidades afines basándose en comportamientos de chat o interacciones previas, perdiendo una oportunidad enorme de construir comunidades cohesionadas.

Diseño de la Reingeniería (To-Be)

Transformación Técnica:

La propuesta es implementar un Motor de Recomendación Híbrido con IA Contextual que combine filtrado colaborativo, análisis de contenido con LLMs y señales contextuales en tiempo real.

Componente 1 - Motor de Embeddings de Contenido:

Cada canal y cada stream recibe un "embedding vectorial" generado por un modelo de lenguaje que analiza: título del stream, juego, idioma, estilo del streamer (inferido de clips del chat y transcripciones de voz a texto), horario habitual, y demografía de su audiencia actual. Estos vectores se almacenan en una base de datos vectorial (Pinecone o Weaviate) que permite búsquedas de similitud ultrarrápidas.

Componente 2 - Perfil Dinámico del Usuario:

Cada usuario tiene un perfil vectorial actualizado en tiempo real que refleja: canales visitados, tiempo de permanencia, interacciones en chat, horarios de conexión, juegos preferidos y el "tono" de los streams que más disfruta (competitivo vs. casual, español vs. inglés, etc.). Este perfil se enriquece con cada sesión.

Componente 3 - Agente de Recomendación Contextual:

Un agente LLM que actúa como "curador personal" y tiene acceso a:

- El perfil vectorial del usuario.



- El catálogo vectorial de streams activos en ese momento.
- Señales contextuales: hora del día, día de la semana, duración promedio de sesiones anteriores del usuario a esa hora.

El agente genera recomendaciones personalizadas en lenguaje natural para la interfaz ("Basado en que anoche viste 3 horas de Valorant, este streamer está en vivo ahora con el mismo juego y tiene un estilo similar al que prefieres") y también alimenta el algoritmo de ranking de la homepage.

Componente 4 - Sistema de Amplificación para Canales Pequeños:

Un mecanismo de "diversity injection" que garantiza que al menos el 20-30% de las recomendaciones mostradas sean canales en crecimiento (menos de 500 viewers) pero con alta compatibilidad vectorial con el usuario. Esto resuelve el problema del "rich get richer" sin sacrificar relevancia.


Infraestructura Cloud:

- Pipeline de datos en tiempo real con Apache Flink para procesar eventos de usuario al instante.
- Base de datos vectorial (Pinecone) para búsquedas de similitud en milisegundos.
- Modelo de recomendación desplegado como microservicio con auto-scaling.
- A/B testing continuo para optimizar el algoritmo por segmento de usuario.



ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA DE SISTEMAS
CONSTRUCCIÓN Y EVOLUCIÓN DEL
SOFTWARE

Flujo Propuesto (To-Be):






ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA DE SISTEMAS
CONSTRUCCIÓN Y EVOLUCIÓN DEL
SOFTWARE

Impacto y Beneficios

Beneficio	Descripción
Personalización real	Cada usuario ve una homepage completamente diferente y relevante para sus gustos
Aumento de tiempo de sesión	Plataformas con recomendaciones personalizadas (Netflix, Spotify) reportan incrementos de 30-50% en tiempo de sesión
Democratización del descubrimiento	Los canales pequeños con contenido de calidad y audiencia compatible tienen la misma oportunidad de ser descubiertos que los grandes
Reducción del churn	Los usuarios que encuentran contenido relevante tienen menor probabilidad de abandonar la plataforma
Conexión de comunidades	El sistema conecta naturalmente a personas con intereses similares, fortaleciendo el sentido de comunidad de Kick
Ventaja competitiva vs. Twitch	Twitch tiene un algoritmo similar pero favorece enormemente a streamers partner; la versión de Kick sería más equitativa y atractiva para creadores emergentes

Diagrama de Arquitectura de Alto Nivel





ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA DE SISTEMAS
CONSTRUCCIÓN Y EVOLUCIÓN DEL
SOFTWARE

Resumen Comparativo de la Reingeniería

Dimensión	Proceso 1: Moderación	Proceso 2: Recomendación
Tecnología As-Is	Filtros por palabras clave + mods humanos	Ranking por número de viewers
Tecnología To-Be	LLM multi-agente + perfilado de usuario	Motor vectorial + agente contextual LLM
Principal limitación resuelta	Escalabilidad y tiempo de respuesta	Personalización y descubrimiento equitativo
Impacto en streamer	Protección 24/7 sin depender de mods	Mayor visibilidad para canales pequeños
Impacto en usuario	Chat más seguro y de mejor calidad	Contenido relevante desde el primer clic
Tecnología clave	Apache Kafka, LLM fine-tuned, Redis	Pinecone (vectorDB), Apache Flink, LLM
Beneficio cuantificable	Reducción ~70% falsos positivos en moderación	Aumento estimado 30-50% en tiempo de sesión

Conclusión

La reingeniería propuesta para Kick.com no implica reconstruir la plataforma desde cero, sino **transformar dos puntos de fricción críticos** mediante la integración inteligente de tecnologías disponibles hoy. La adopción de arquitecturas multi-agente con LLMs, bases de datos vectoriales y procesamiento de streams en tiempo real convierte procesos manuales, lentos y no escalables en sistemas autónomos, precisos y que mejoran continuamente.

Ambas propuestas atacan directamente el talón de Aquiles de Kick frente a Twitch: la capacidad de escalar sin perder la calidad de la experiencia del usuario. Un chat seguro y un feed relevante son los dos factores que más influyen en la retención de usuarios y streamers en plataformas de streaming en vivo.